EDA STEAM GAMES





EQUIPO



MIGUEL ANGEL VELEZ



EMANUEL GALLEGO RODRIGUEZ



ALEJANDRO JARAMILLO ARIAS



CONTENIDO

01 Problema

02 Dataset

03 Clasificación de variables

04 Análisis Exploratorio

05 Enfoque de mercado y audiencia

06 Variables de Monetizacion y audiencia.

07 Conclusiones

PROBLEMA

Debido al volumen masivo del catálogo de Steam, el reto principal es transformar esa gran cantidad de datos en información clara para identificar patrones sobre precios, popularidad, descuentos y valoraciones que permitan entender mejor el mercado.



🎮 Gran cantidad de juegos



💰 Precios y descuentos variables



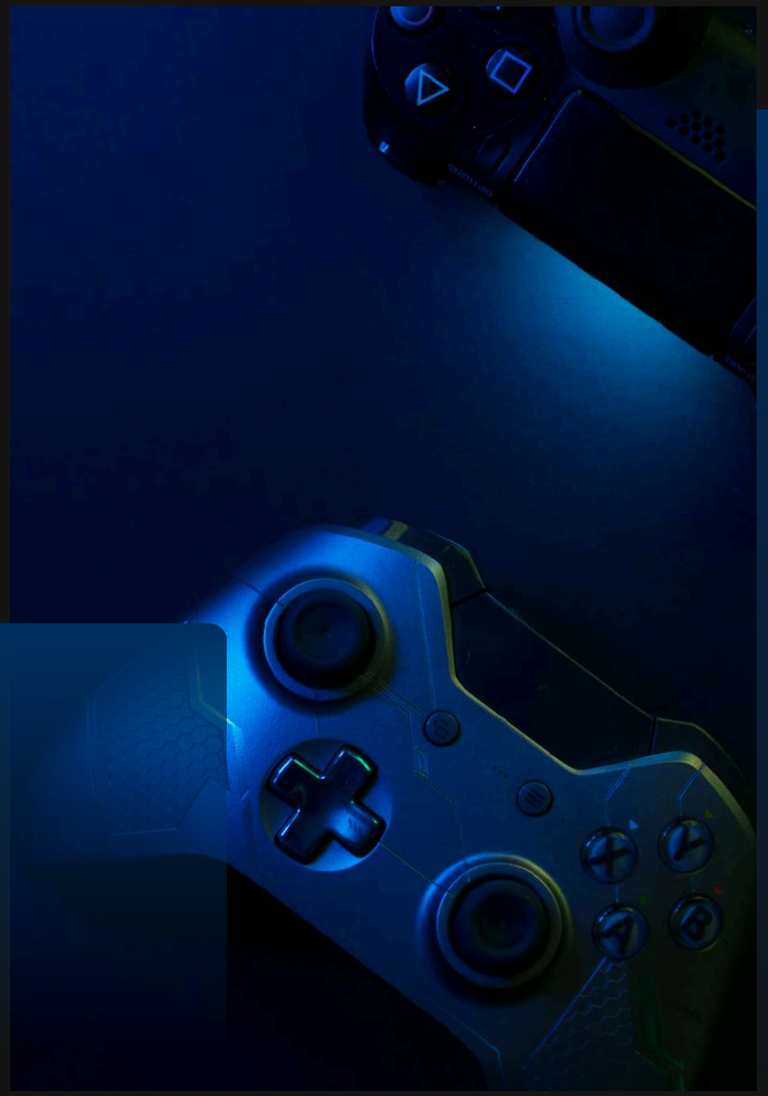
👥Popularidad desigual

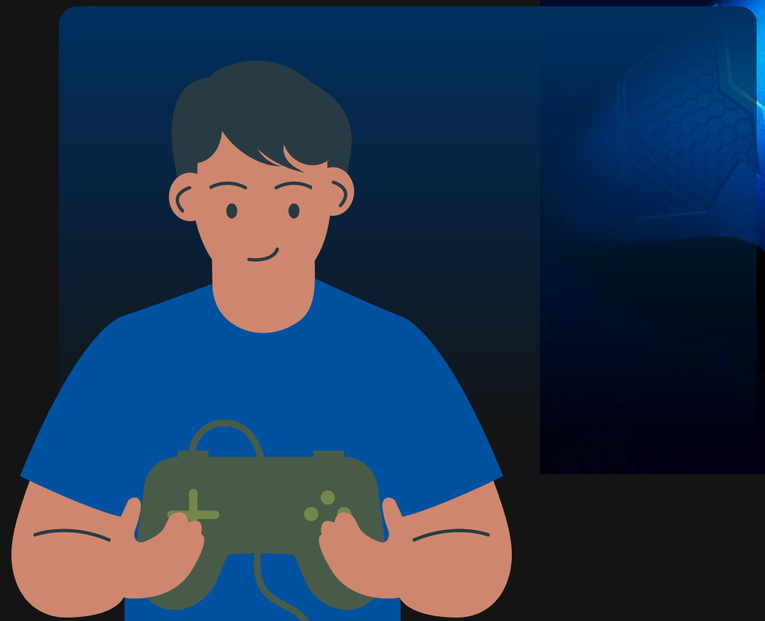


⭐ Valoración y percepción

DATASET

Este dataset es una recopilación de información extraída de la API pública de Steam (y repositorios de Kaggle), que incluye metadatos de miles de videojuegos como precios, desarrolladores, géneros, reseñas de la comunidad y número de jugadores activos.





Clasificación de variables



01
CATEGÓRICAS
- Género
- Categorías
- Plataforma

02
NUMÉRICAS
- Precio
- Descuento
- CCU

03
IDENTIFICACIÓN / TEMPORALES
- AppID
- Fecha de lanzamiento
- Propietarios estimados



ANÁLISIS EXPLORATORIO

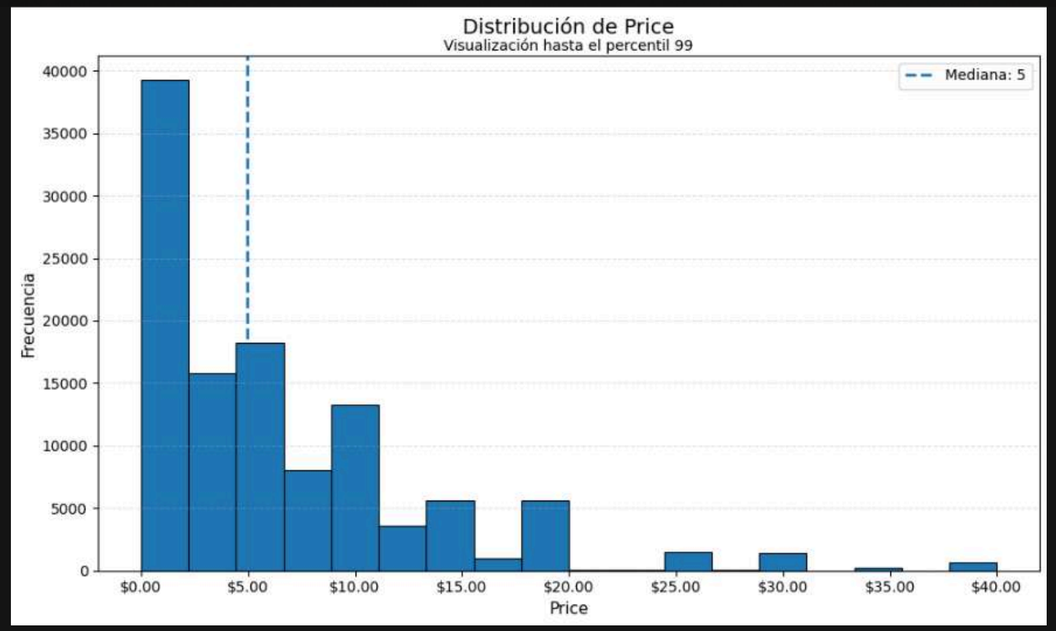
🟦 1. Precios/Monetización:

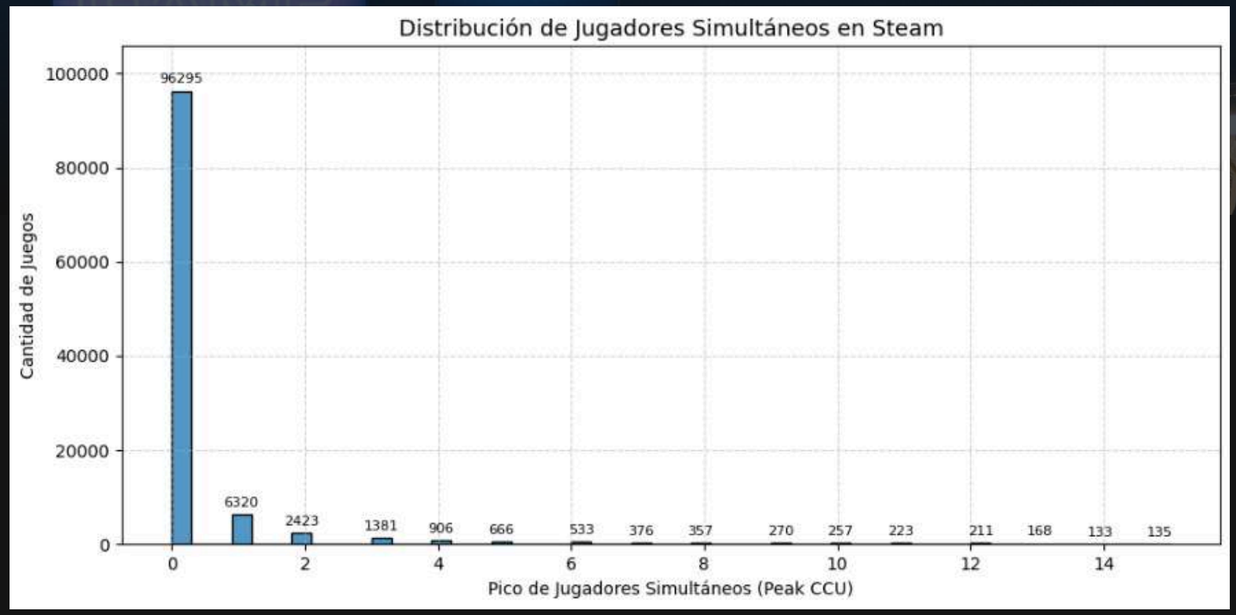
El catálogo se concentra fuertemente en el rango de $0 a $20 USD. Salvo en grandes producciones, los precios se mantienen accesibles para reducir la barrera de entrada al usuario.

🟦 2. Popularidad:

La mayoría de los juegos registra muy pocos jugadores simultáneos frente a unos pocos éxitos. Además, el 77.5% es exclusivo de Windows y solo el 9.9% es multiplataforma total.

💰 Distribución de precios de los videojuegos





🎮 Distribución de jugadores simultáneos

Monetización y audiencia





PRECIOS Y MONETIZACIÓN

Análisis comercial de un mercado dominado por juegos de pago (85.2%) a $4.99 USD promedio. Estudiamos cómo los descuentos clave (50%–90%) potencian las ventas y cómo los títulos consolidados sostienen valores de hasta $32.49 USD.

POPULARIDAD Y AUDIENCIA

Evaluación de un mercado asimétrico donde solo el 1.6% logra éxito masivo y el 98.4% no supera los 100 usuarios simultáneos. Analizamos el Peak CCU y el alcance de los juegos Free-to-Play.

VARIABLES DE MONETIZACIÓN Y AUDIENCIA

Analizamos las distribuciones y relaciones entre métricas clave para descubrir patrones de éxito comercial, audiencia, publico y precios dentro de steam.



PRECIO

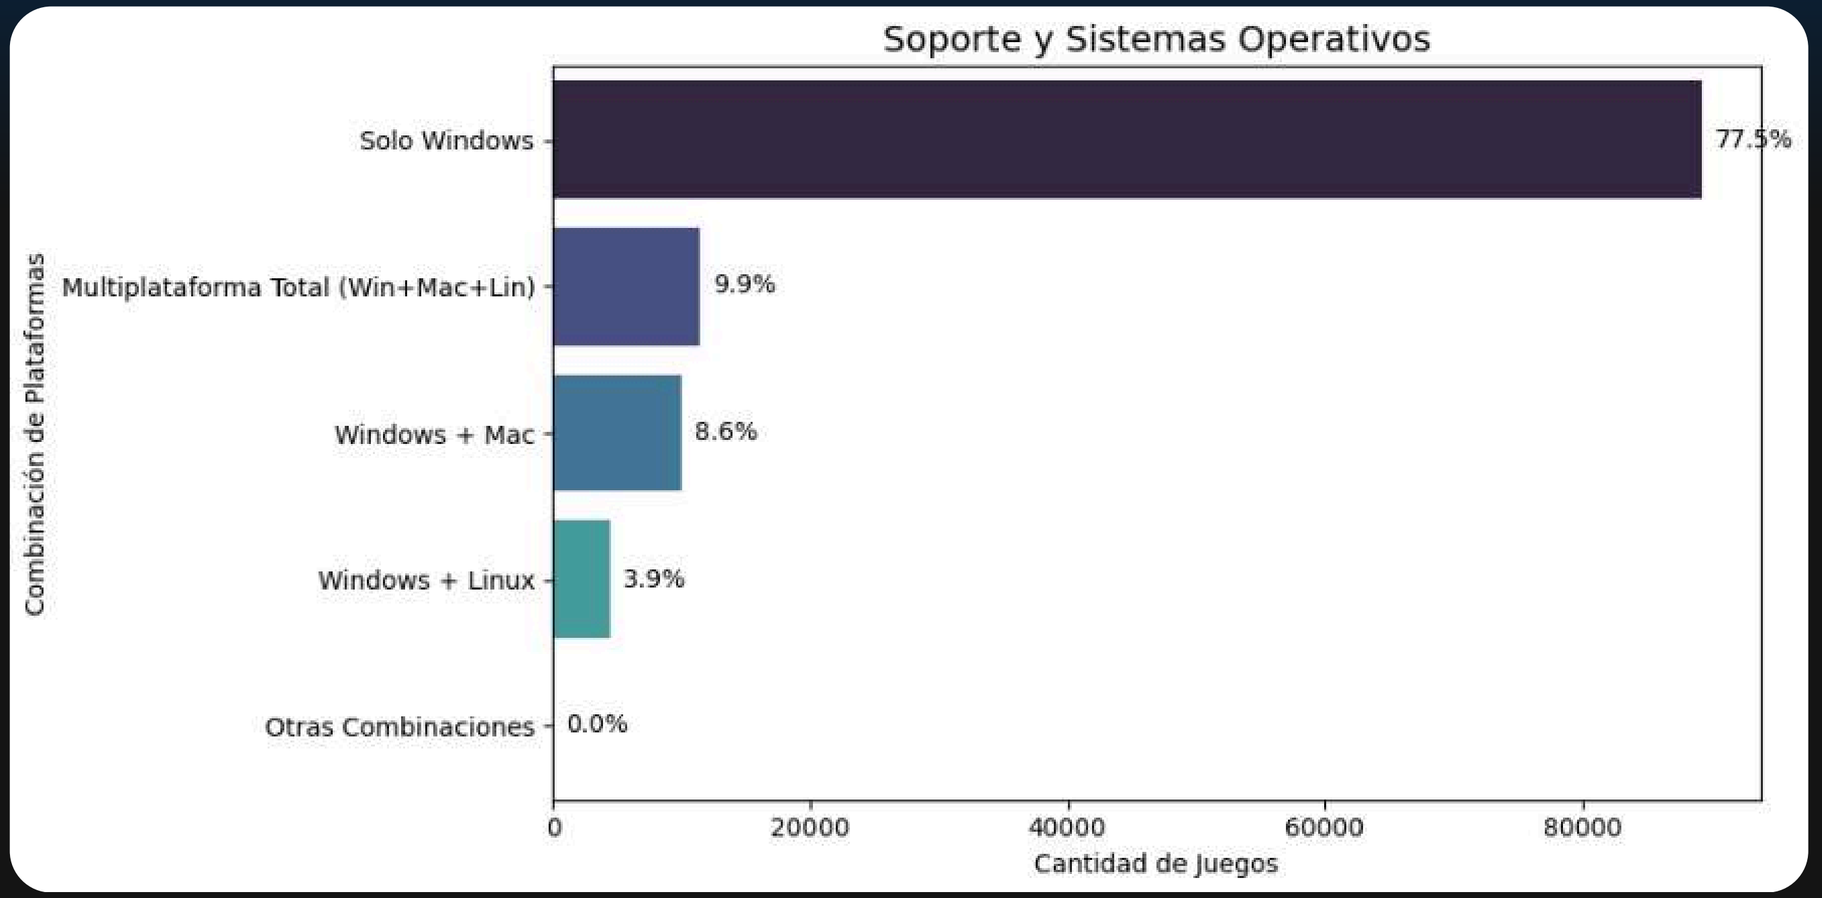
La mayoría de juegos presenta precios bajos.

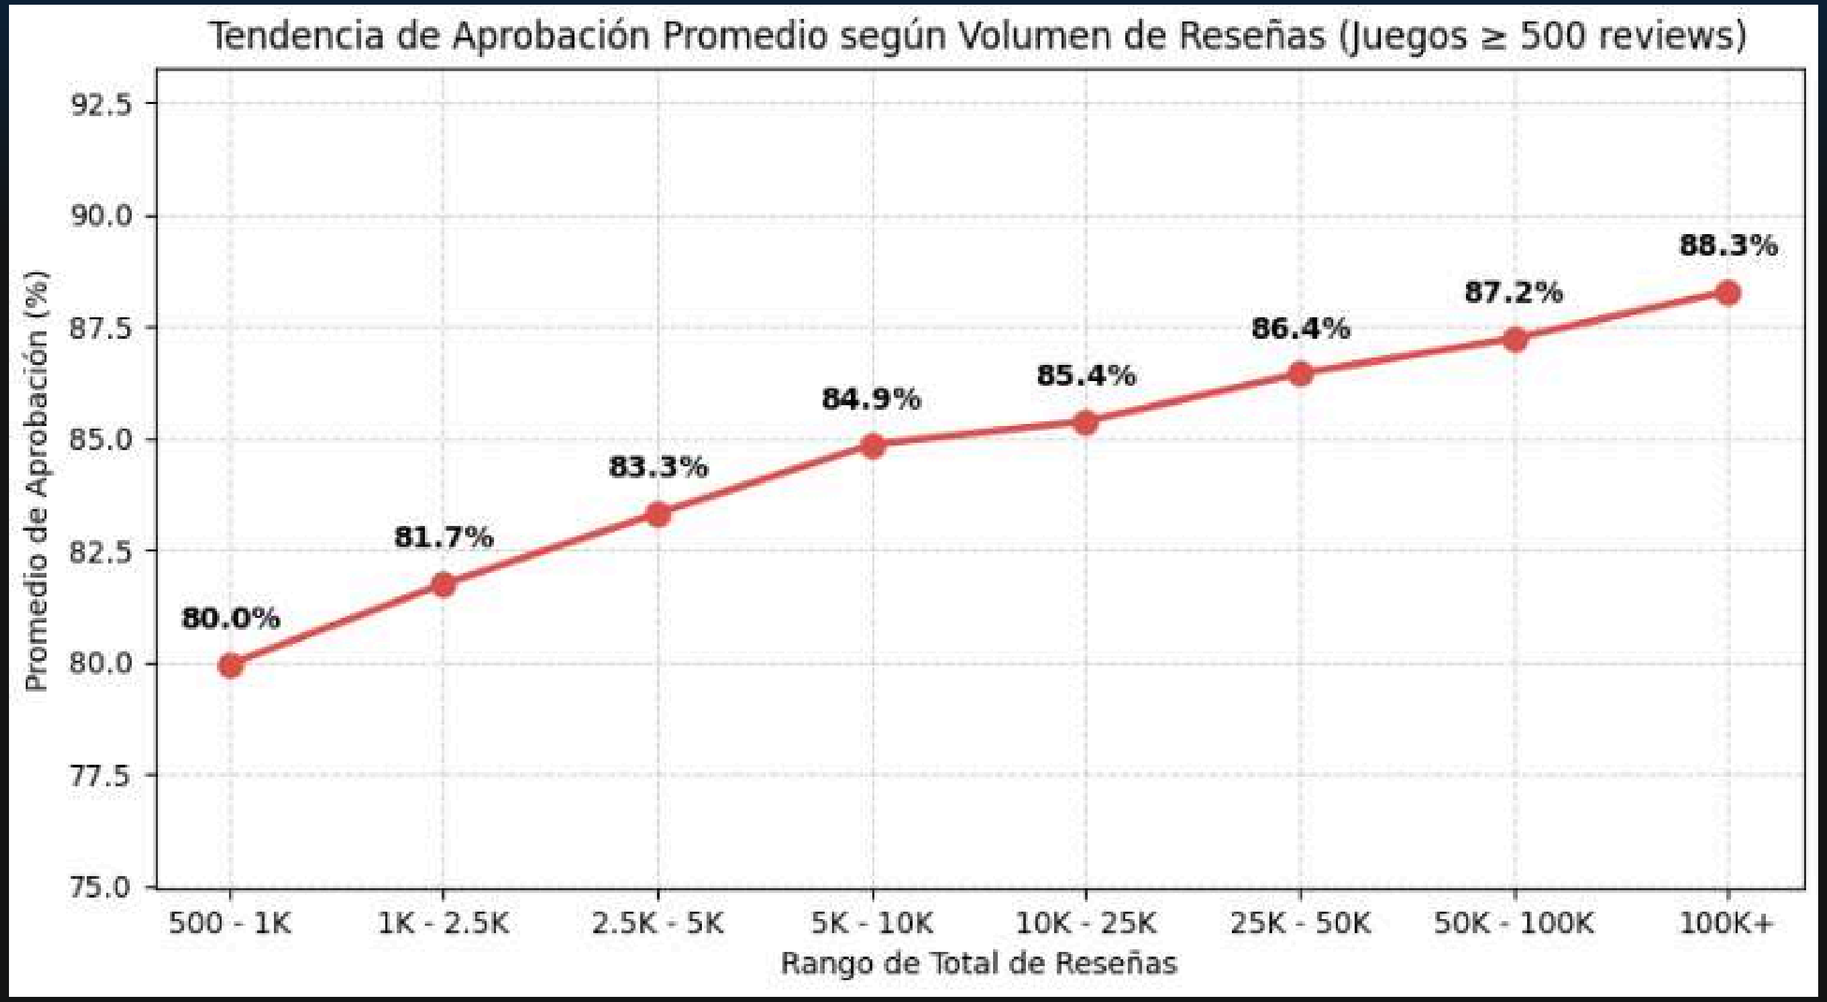
RESEÑAS

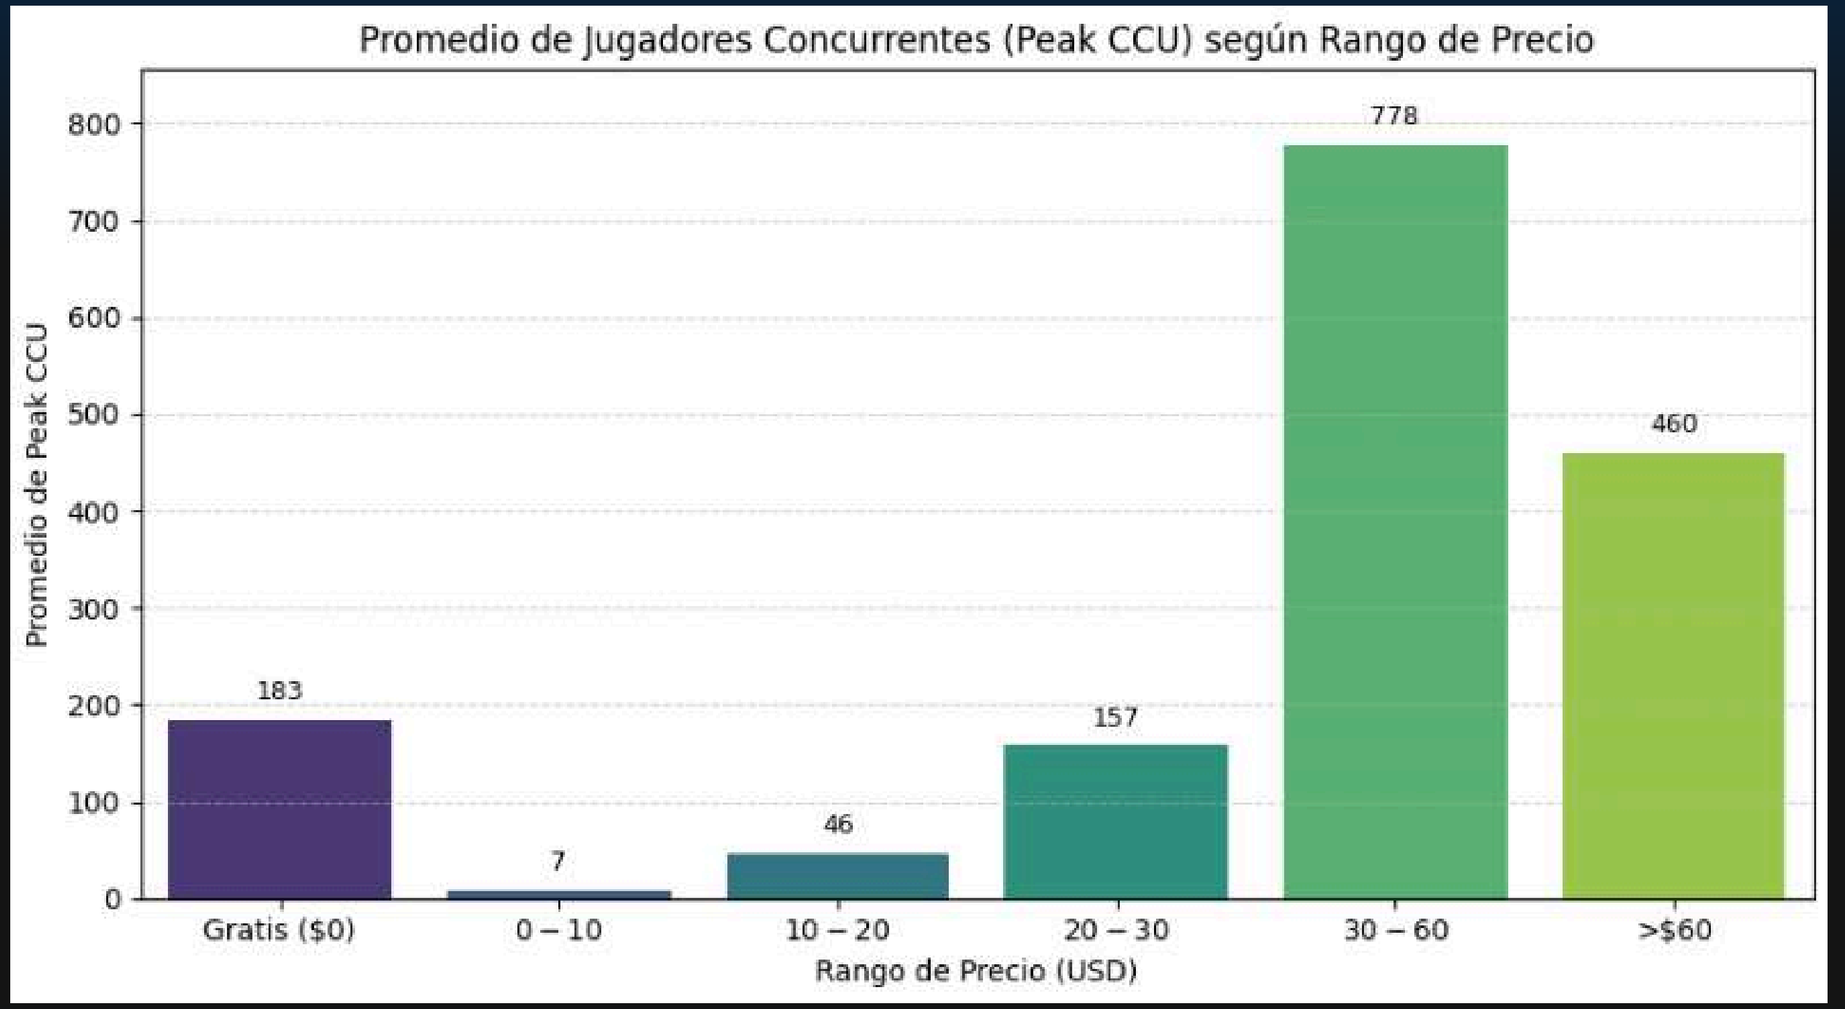
Las reseñas muestran una distribución muy desigual entre juegos.

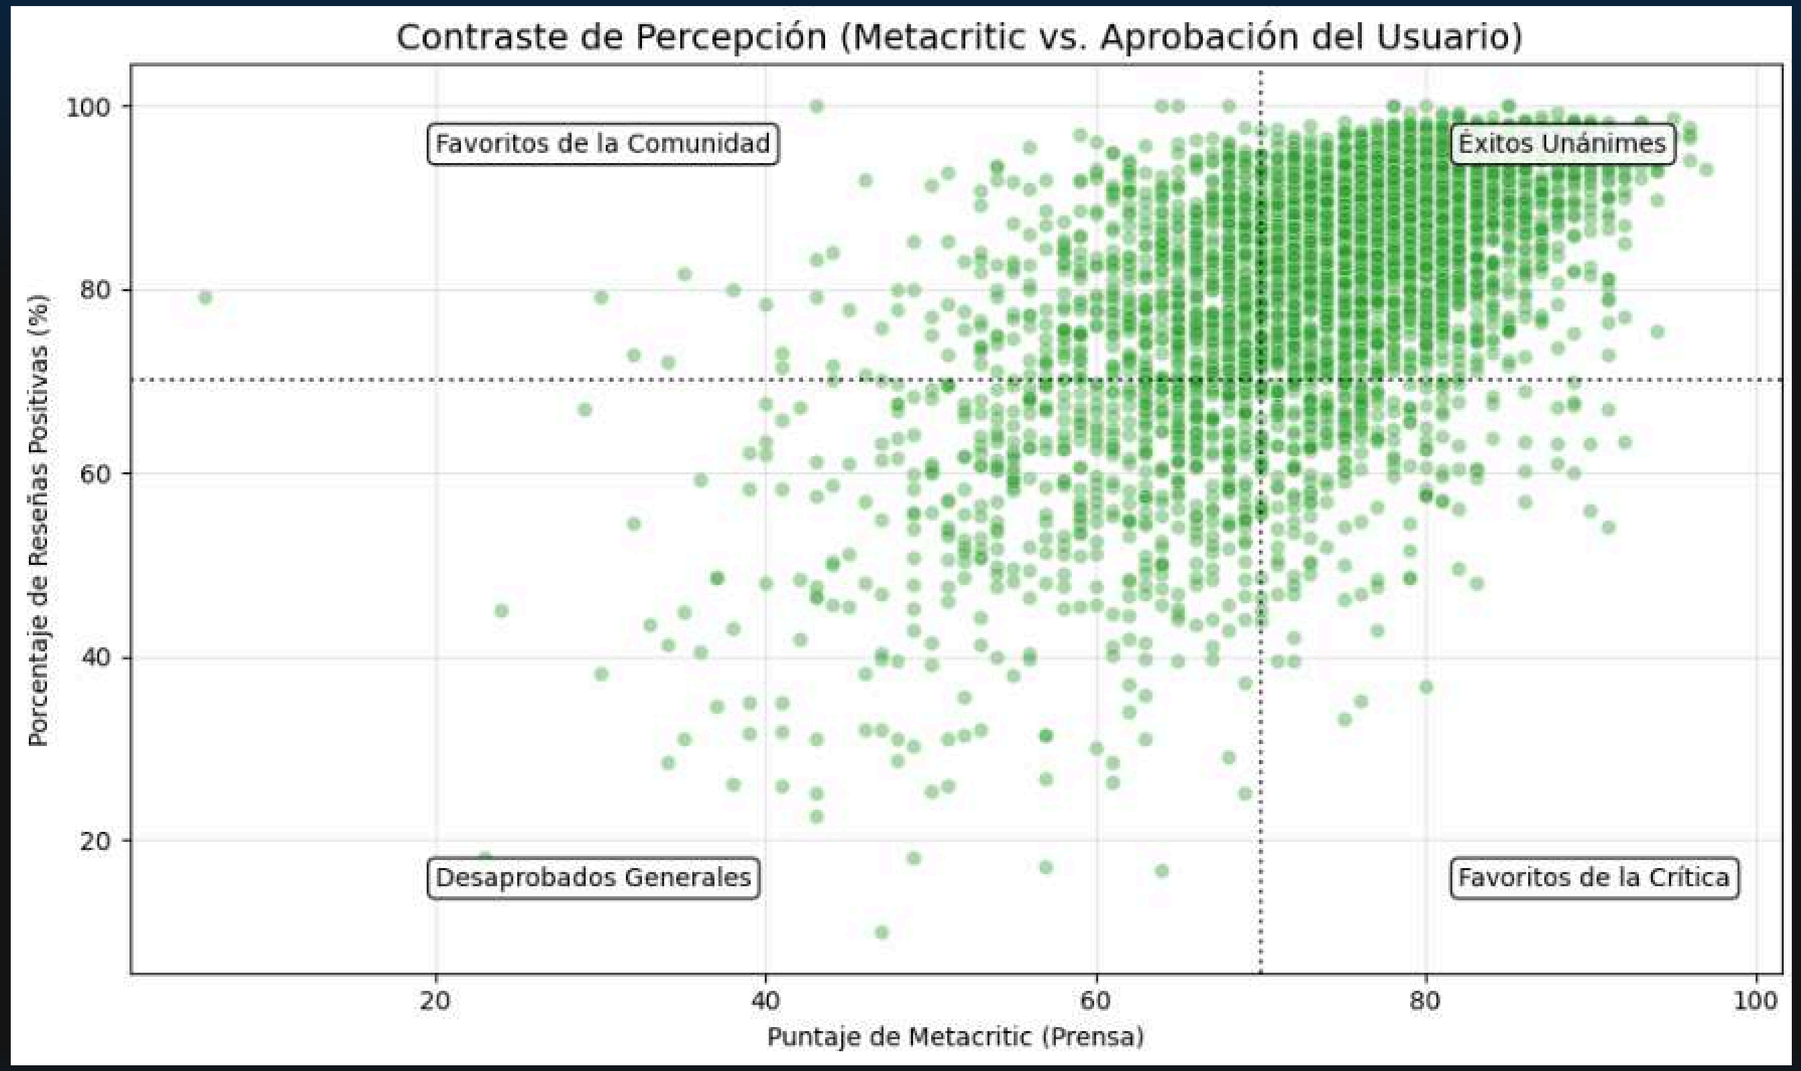
POPULARIDAD

Un grupo reducido de juegos concentra gran cantidad de jugadores.


Soporte y Sistemas Operativos
Solo Windows
77.5%
Multiplataforma Total (Win+Mac+Lin)
9.9%
Windows + Mac
8.6%
Windows + Linux
3.9%
Otras Combinaciones
0.0%
Combinación de Plataformas
0
20000
40000
60000
80000
Cantidad de Juegos

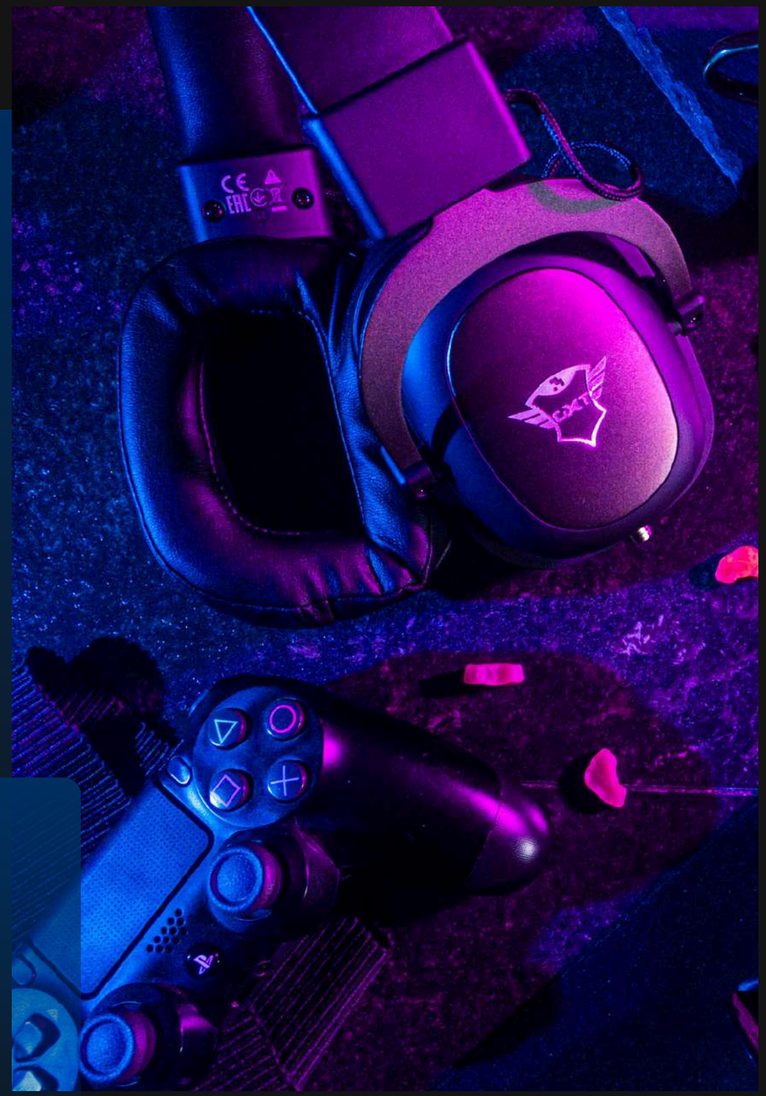

Tendencia de Aprobación Promedio según Volumen de Reseñas (Juegos ≥ 500 reviews)
Promedio de Aprobación (%)
92.5
90.0
87.5
85.0
82.5
80.0
77.5
75.0
80.0%
81.7%
83.3%
84.9%
85.4%
86.4%
87.2%
88.3%
500 - 1K
1K - 2.5K
2.5K - 5K
5K - 10K
10K - 25K
25K - 50K
50K - 100K
100K+
Rango de Total de Reseñas


Promedio de Jugadores Concurrentes (Peak CCU) según Rango de Precio
Promedio de Peak CCU
0
100
200
300
400
500
600
700
800
183
7
46
157
778
460
Gratis ($0)
0 – 10
10 – 20
20 – 30
30 – 60
>$60
Rango de Precio (USD)


Contraste de Percepción (Metacritic vs. Aprobación del Usuario)
Favoritos de la Comunidad
Éxitos Unánimes
Desaprobados Generales
Favoritos de la Crítica
Porcentaje de Reseñas Positivas (%)
Puntaje de Metacritic (Prensa)
100
80
60
40
20
20
40
60
80
100

MODELO

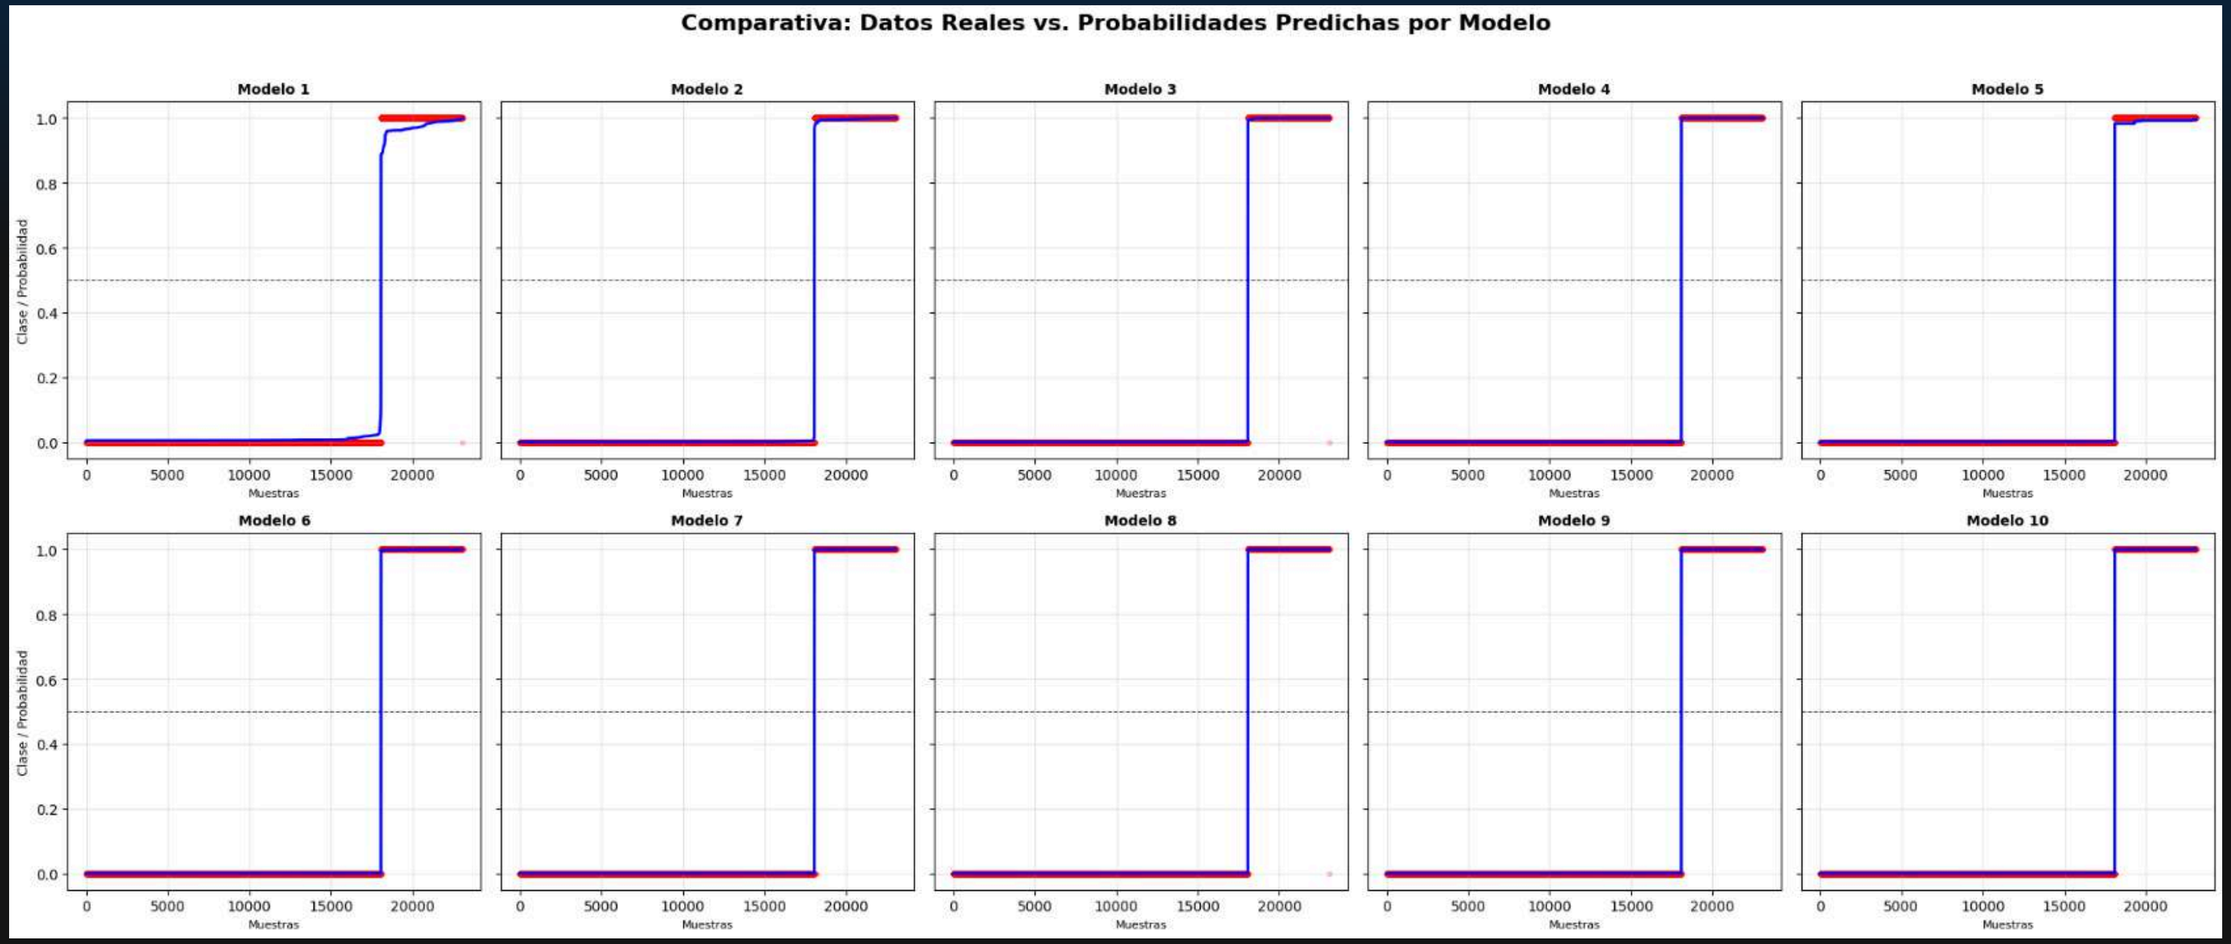
Este proyecto utiliza un modelo de Regresión Logística para predecir si un videojuego en Steam superará el umbral de ventas para considerarse un éxito. Analizamos variables clave como precio, reseñas y géneros, asegurando la calidad de los datos mediante técnicas de imputación (SimpleImputer y KNNImputer) para aprovechar al máximo cada registro.





Entrenando y evaluando las 10 variantes de Regresión Logística...

	Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
0	Modelo 5: RegLog (C=0.01, L1, liblinear)	1.0	1.0000	1.0	1.0000	1.0000
1	Modelo 4: RegLog (C=10.0, L2, lbfgs)	1.0	1.0000	1.0	1.0000	1.0000
2	Modelo 9: RegLog (C=100.0, L2, lbfgs)	1.0	1.0000	1.0	1.0000	1.0000
3	Modelo 10: RegLog (Sin Regularización, lbfgs)	1.0	1.0000	1.0	1.0000	1.0000
4	Modelo 6: RegLog (C=0.1, L1, liblinear)	1.0	1.0000	1.0	1.0000	1.0000
5	Modelo 1: RegLog (C=0.01, L2, lbfgs)	1.0	0.9998	1.0	0.9999	0.9999
6	Modelo 2: RegLog (C=0.1, L2, lbfgs)	1.0	0.9998	1.0	0.9999	1.0000
7	Modelo 3: RegLog (C=1.0, L2, lbfgs - Default)	1.0	0.9998	1.0	0.9999	0.9999
8	Modelo 8: RegLog (C=10.0, L1, liblinear)	1.0	0.9998	1.0	0.9999	0.9999
9	Modelo 7: RegLog (C=1.0, L1, liblinear)	1.0	0.9998	1.0	0.9999	1.0000


Comparativa: Datos Reales vs. Probabilidades Predichas por Modelo
Modelo 1
Modelo 2
Modelo 3
Modelo 4
Modelo 5
Modelo 6
Modelo 7
Modelo 8
Modelo 9
Modelo 10
Clase / Probabilidad
Muestras
0.0
0.2
0.4
0.6
0.8
1.0
0
5000
10000
15000
20000

MODELO 5

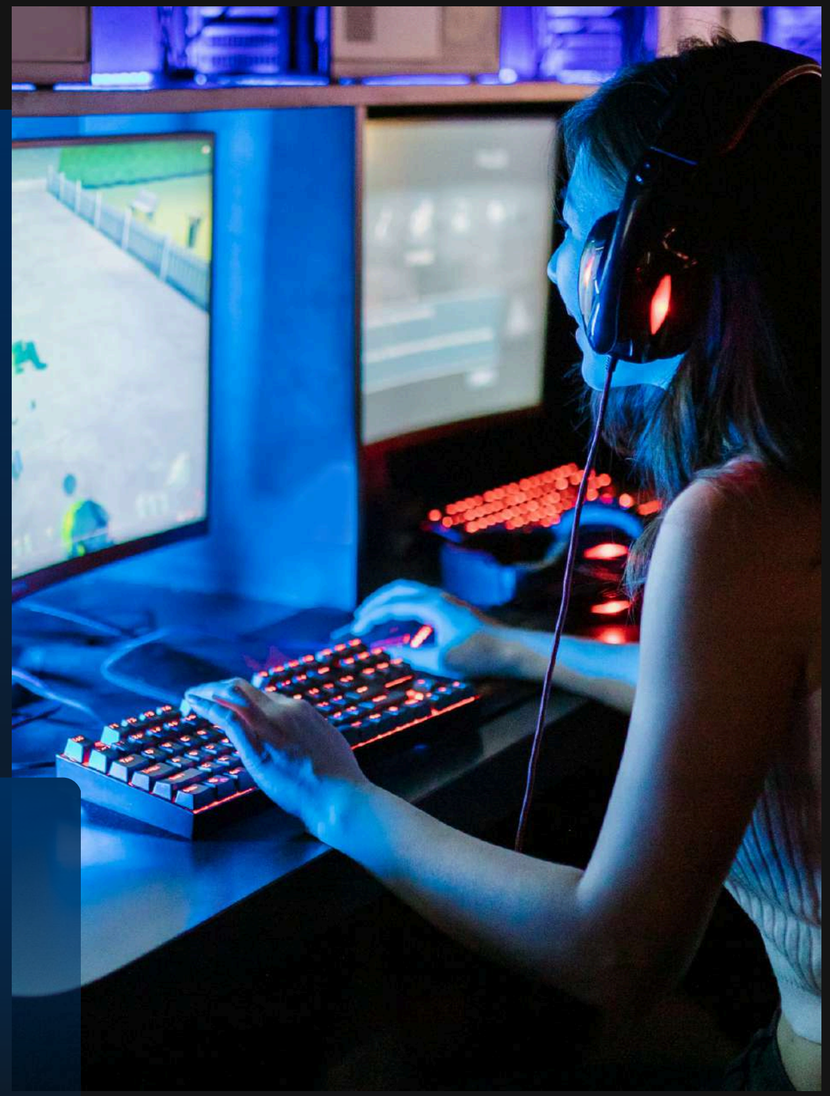
El Modelo 5 fue el ganador porque combinó KNNImputer y Regresión Logística, logrando el desempeño más alto en F1-Score y Accuracy. La imputación por vecinos cercanos preservó la relación entre las variables de los juegos, permitiendo identificar con mayor precisión qué títulos alcanzan el Éxito Comercial sin introducir sesgos en los datos faltantes.



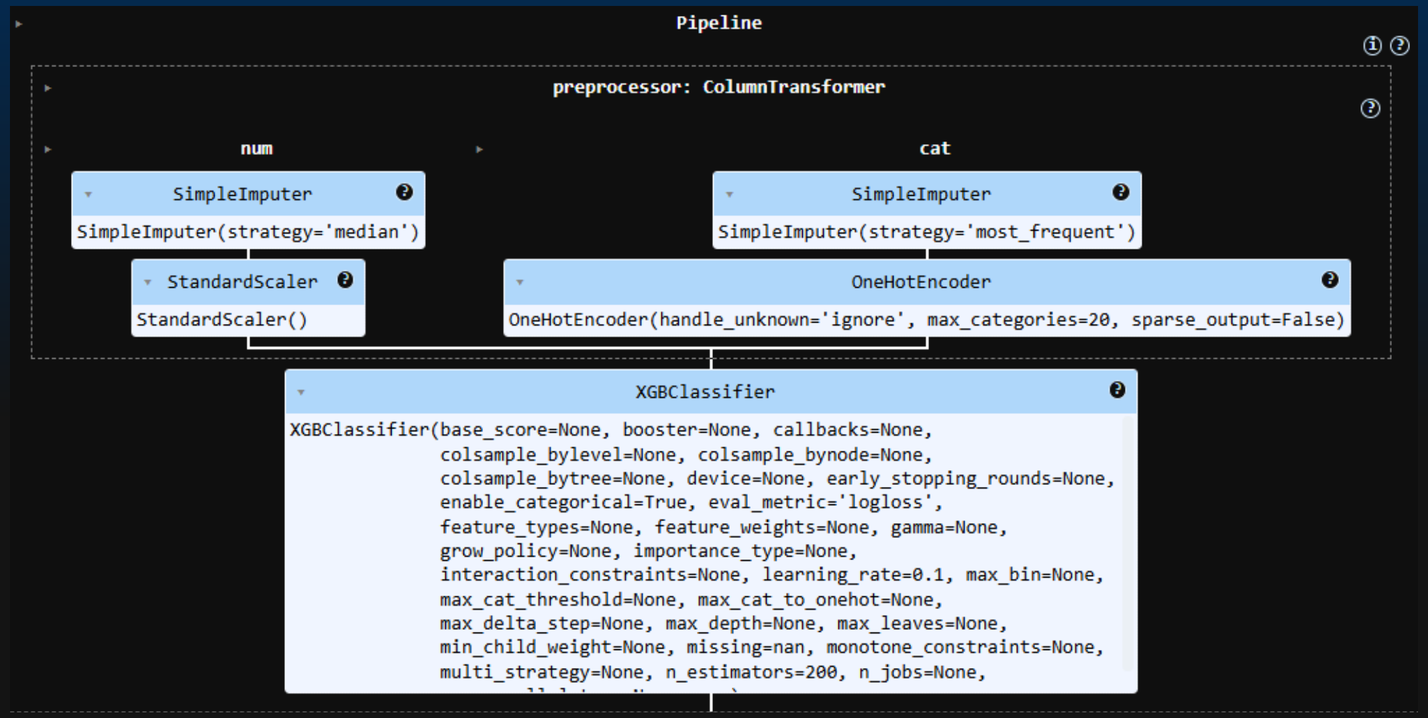
PIPELINES

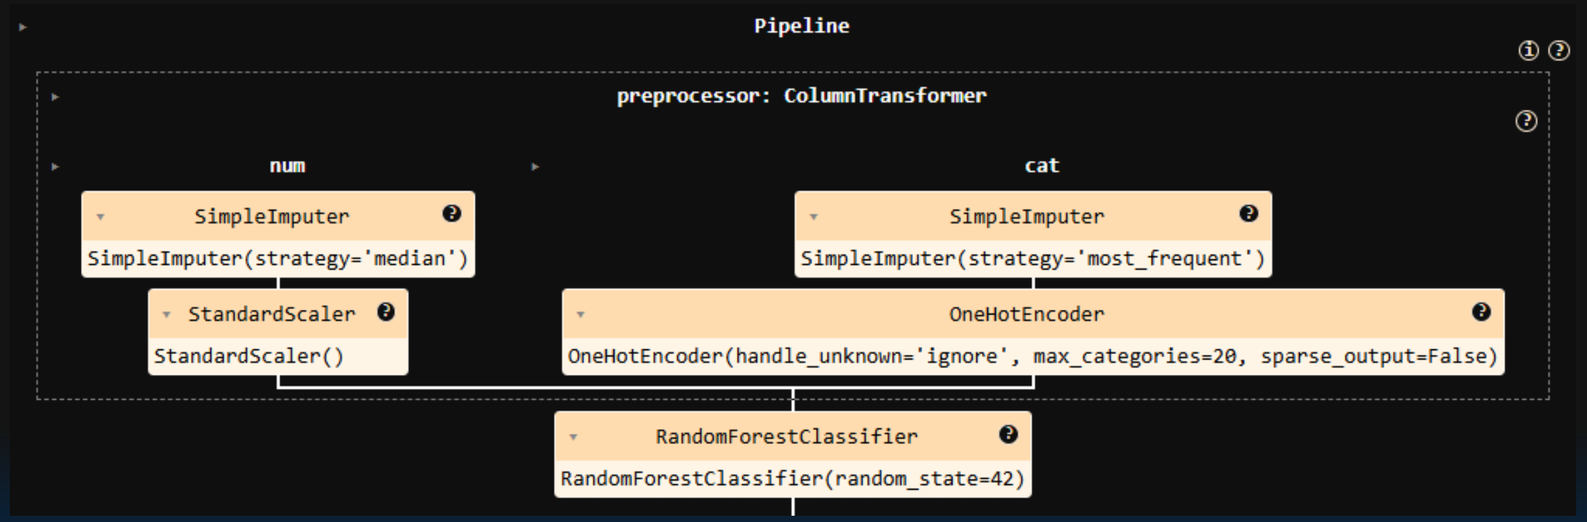
Preprocesamiento (ColumnTransformer): Separa y trata las variables numéricas (con SimpleImputer para nulos y StandardScaler) y las categóricas (con imputación de valores más frecuentes y OneHotEncoder).

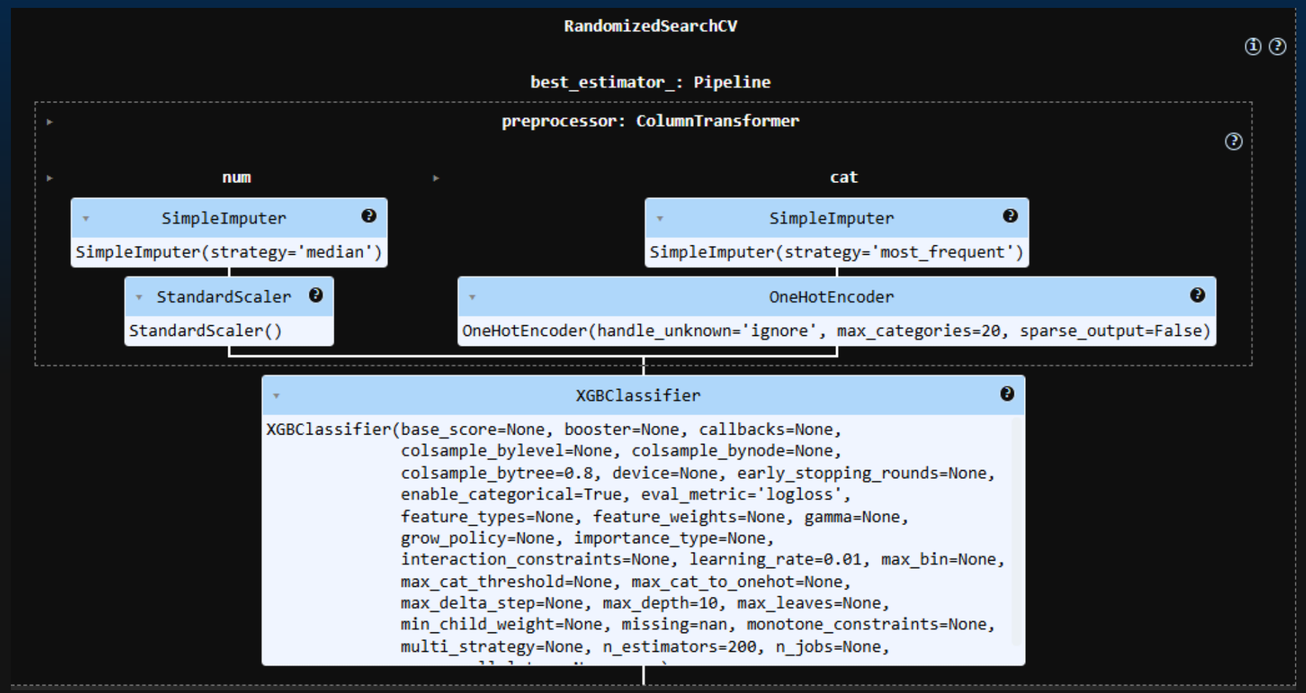
Modelado: Conecta automáticamente los datos ya limpios y transformados con los algoritmos de clasificación evaluados (como KNeighborsClassifier o árboles) para entrenar el modelo de forma limpia y sin fugas de datos.






Pipeline
preprocessor: ColumnTransformer
num
SimpleImputer
SimpleImputer(strategy='median')
StandardScaler
StandardScaler()
cat
SimpleImputer
SimpleImputer(strategy='most_frequent')
OneHotEncoder
OneHotEncoder(handle_unknown='ignore', max_categories=20, sparse_output=False)
XGBClassifier
XGBClassifier(base_score=None, booster=None, callbacks=None,
colsample_bylevel=None, colsample_bynode=None,
colsample_bytree=None, device=None, early_stopping_rounds=None,
enable_categorical=True, eval_metric='logloss',
feature_types=None, feature_weights=None, gamma=None,
grow_policy=None, importance_type=None,
interaction_constraints=None, learning_rate=0.1, max_bin=None,
max_cat_threshold=None, max_cat_to_onehot=None,
max_delta_step=None, max_depth=None, max_leaves=None,
min_child_weight=None, missing=nan, monotone_constraints=None,
multi_strategy=None, n_estimators=200, n_jobs=None,


Pipeline
preprocessor: ColumnTransformer
num
SimpleImputer
SimpleImputer(strategy='median')
StandardScaler
StandardScaler()
cat
SimpleImputer
SimpleImputer(strategy='most_frequent')
OneHotEncoder
OneHotEncoder(handle_unknown='ignore', max_categories=20, sparse_output=False)
RandomForestClassifier
RandomForestClassifier(random_state=42)



--- HISTORIAL COMPLETO DE ITERACIONES (Ordenado por mejor desempeño) ---

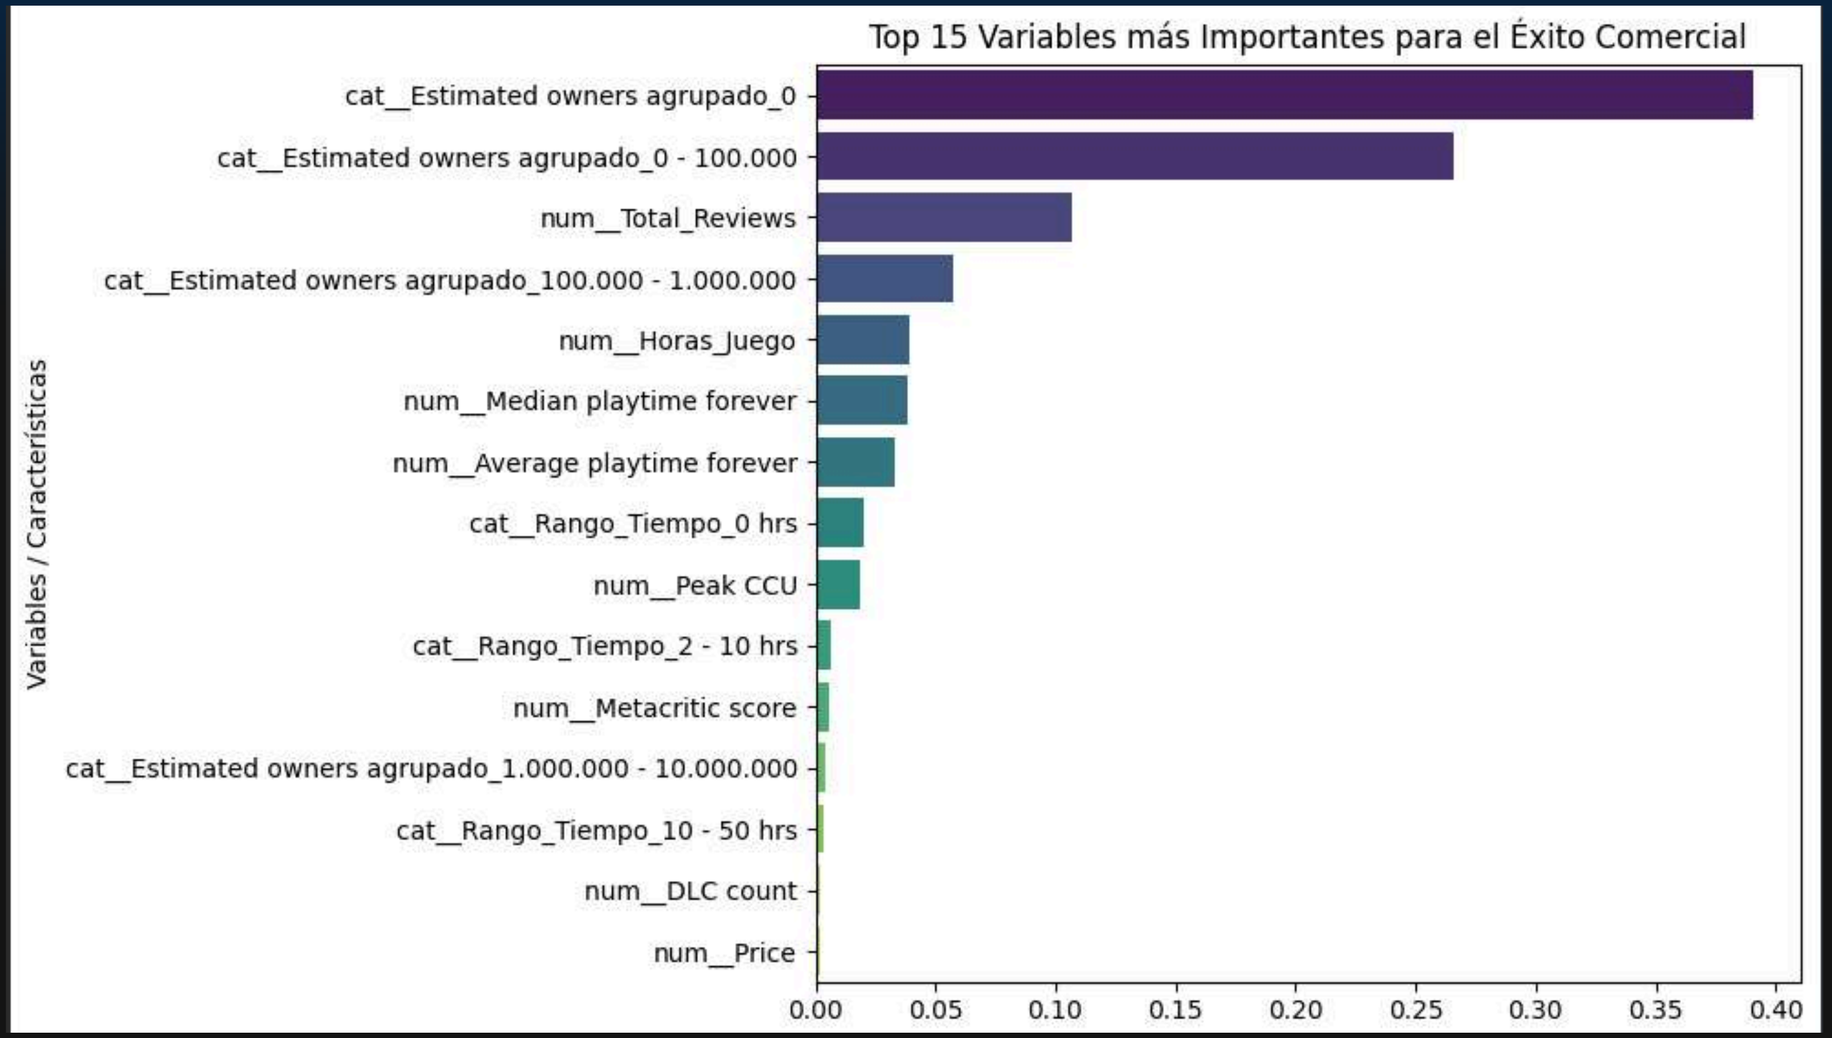
	param_classifier__n_estimators	param_classifier__max_depth	param_classifier__min_samples_split	param_classifier__min_samples_leaf	mean_test_score	std_test_score	rank_test_score
0	300	None	5	2	1.0	0.000000e+00	1
1	200	10	5	1	1.0	0.000000e+00	1
2	100	40	10	1	1.0	4.965068e-17	1
3	200	20	5	1	1.0	0.000000e+00	1
4	100	40	2	1	1.0	0.000000e+00	1
5	300	None	2	2	1.0	0.000000e+00	1
6	50	None	2	4	1.0	0.000000e+00	1
7	50	10	10	4	1.0	4.965068e-17	1
8	100	30	5	1	1.0	0.000000e+00	1
9	200	30	10	1	1.0	9.930137e-17	1
10	100	20	10	2	1.0	0.000000e+00	1
11	300	40	2	2	1.0	0.000000e+00	1
12	100	10	10	4	1.0	0.000000e+00	1
13	200	30	10	4	1.0	0.000000e+00	1
14	100	10	10	1	1.0	4.965068e-17	1

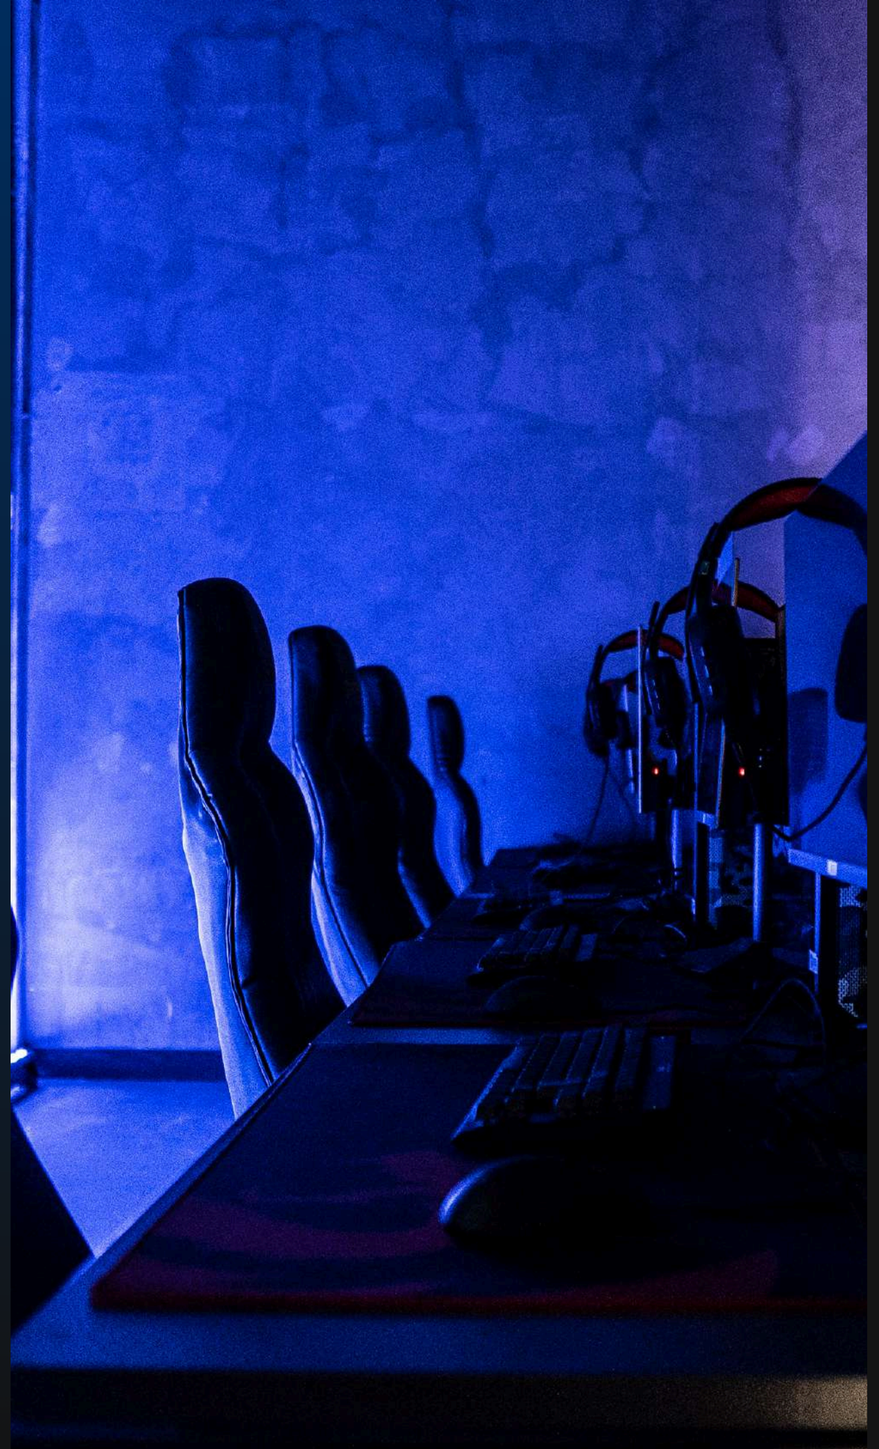


FEATURE IMPORTANCE

El éxito comercial en Steam está determinado principalmente por el volumen de la comunidad. El análisis de importancia muestra que las categorías de propietarios (Estimated owners) y el total de reseñas (Total_Reviews), seguidas de cerca por el tiempo de juego (Horas_Juego), son los factores que más peso tienen para el modelo al clasificar un videojuego como exitoso, dejando en un plano secundario a variables como el precio o los DLCs.




Top 15 Variables más Importantes para el Éxito Comercial
Variables / Características
cat__Estimated owners agrupado_0
cat__Estimated owners agrupado_0 - 100.000
num__Total_Reviews
cat__Estimated owners agrupado_100.000 - 1.000.000
num__Horas_Juego
num__Median playtime forever
num__Average playtime forever
cat__Rango_Tiempo_0 hrs
num__Peak CCU
cat__Rango_Tiempo_2 - 10 hrs
num__Metacritic score
cat__Estimated owners agrupado_1.000.000 - 10.000.000
cat__Rango_Tiempo_10 - 50 hrs
num__DLC count
num__Price
0.00
0.05
0.10
0.15
0.20
0.25
0.30
0.35
0.40



FUGA DE DATOS Y DATA DRIFT

Control de Calidad y Estabilidad del Modelo:

Auditoría de Fuga de Datos: Se verificó la correlación con el target, confirmando que todas las variables se encuentran en un estado seguro (sin correlaciones anómalas o excesivas).

Control de Data Drift: Al evaluar la estabilidad de la población entre Train y Test mediante el índice PSI, todas las variables presentan un estado estable (valores muy bajos de PSI).

Optimización: El historial de búsqueda evaluó 50 iteraciones para sintonizar los hiperparámetros del clasificador con alta precisión.

```
=== PUNTO 1: AUDITORÍA DE FUGA DE DATOS ===
Tabla de Control de Correlación (Top variables con mayor relación al Target):
```

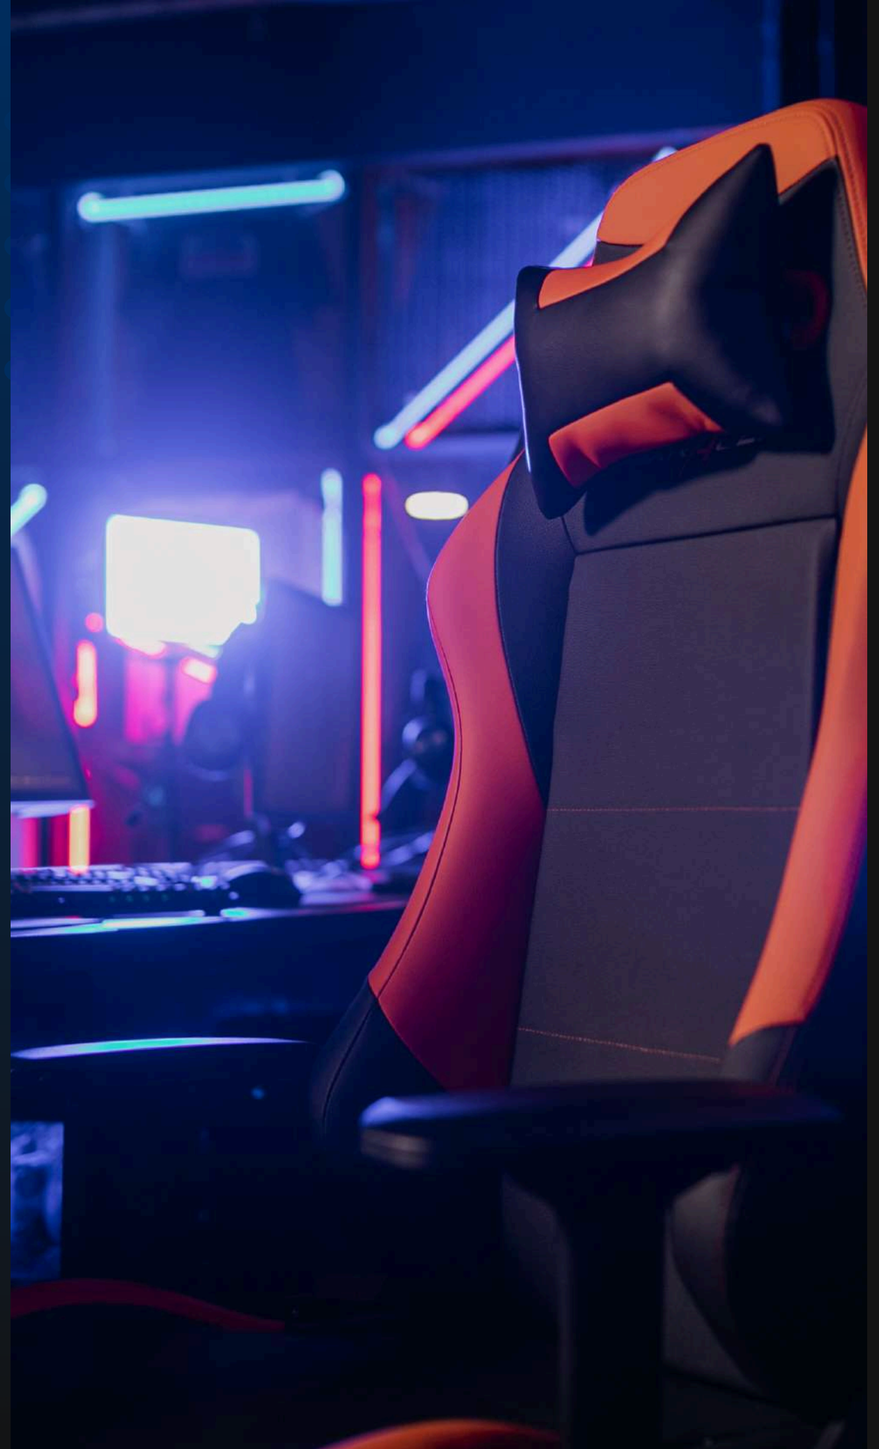
	Variable	Correlacion_Con_Target	Correlacion_Absoluta	Estado_Verificacion
0	Metacritic score	0.299795	0.299795	✓ Seguro
1	Required age	0.114462	0.114462	✓ Seguro
2	Discount	0.107559	0.107559	✓ Seguro
3	Price	0.086098	0.086098	✓ Seguro
4	Total_Reviews	0.065010	0.065010	✓ Seguro
5	Average playtime forever	0.048011	0.048011	✓ Seguro
6	Horas_Juego	0.048011	0.048011	✓ Seguro
7	DLC count	0.037367	0.037367	✓ Seguro
8	Median playtime forever	0.033276	0.033276	✓ Seguro
9	Peak CCU	0.025152	0.025152	✓ Seguro

```
=== PUNTO 2: TABLA DE CONTROL DE DATA DRIFT ===
Tabla de Control - Estabilidad de Población (Train vs Test):
```

	Variable	Indice_PSI	Estatus_Deriva
0	2	0.0005	✓ Estable
1	10	0.0005	✓ Estable
2	7	0.0003	✓ Estable
3	9	0.0003	✓ Estable
4	16	0.0002	✓ Estable
5	15	0.0002	✓ Estable
6	8	0.0001	✓ Estable
7	12	0.0001	✓ Estable
8	43	0.0001	✓ Estable
9	3	0.0000	✓ Estable
10	0	0.0000	✓ Estable
11	1	0.0000	✓ Estable
12	11	0.0000	✓ Estable
13	4	0.0000	✓ Estable
14	5	0.0000	✓ Estable

```
=== PUNTO 3: TABLA DE CONTROL DE ITERACIONES (Historial de Búsqueda) ===
Total de iteraciones probadas: 50
Mostrando el Top 10 de combinaciones ganadoras:
```

	param_classifier__n_estimators	param_classifier__min_samples_split	param_classifier__min_samples_leaf	param_classifier__max_depth	mean_test_score	std_test_score	rank_test_score
0	300	5	2	None	1.0	0.000000e+00	1
1	200	5	1	10	1.0	0.000000e+00	1
2	100	10	1	40	1.0	4.965068e-17	1
3	200	5	1	20	1.0	0.000000e+00	1
4	100	2	1	40	1.0	0.000000e+00	1
5	300	2	2	None	1.0	0.000000e+00	1
6	50	2	4	None	1.0	0.000000e+00	1
7	50	10	4	10	1.0	4.965068e-17	1
8	100	5	1	30	1.0	0.000000e+00	1
9	200	10	1	30	1.0	9.930137e-17	1



Curva ROC / AUC: El modelo alcanza un AUC de 1.0, lo que indica una capacidad predictiva perfecta para discriminar entre juegos exitosos y no exitosos en los datos de prueba.

Matriz de Confusión: Muestra clasificaciones impecables con cero falsos positivos y cero falsos negativos (18,076 verdaderos negativos y 4,982 verdaderos positivos).

Métricas Globales: Tanto Random Forest Optimizado como XGBoost Optimizado logran un 1.0 en Accuracy, Precision, Recall y F1-Score.

MODELO GANADOR, CURVA ROC Y MATRIZ DE CONFUSIÓN

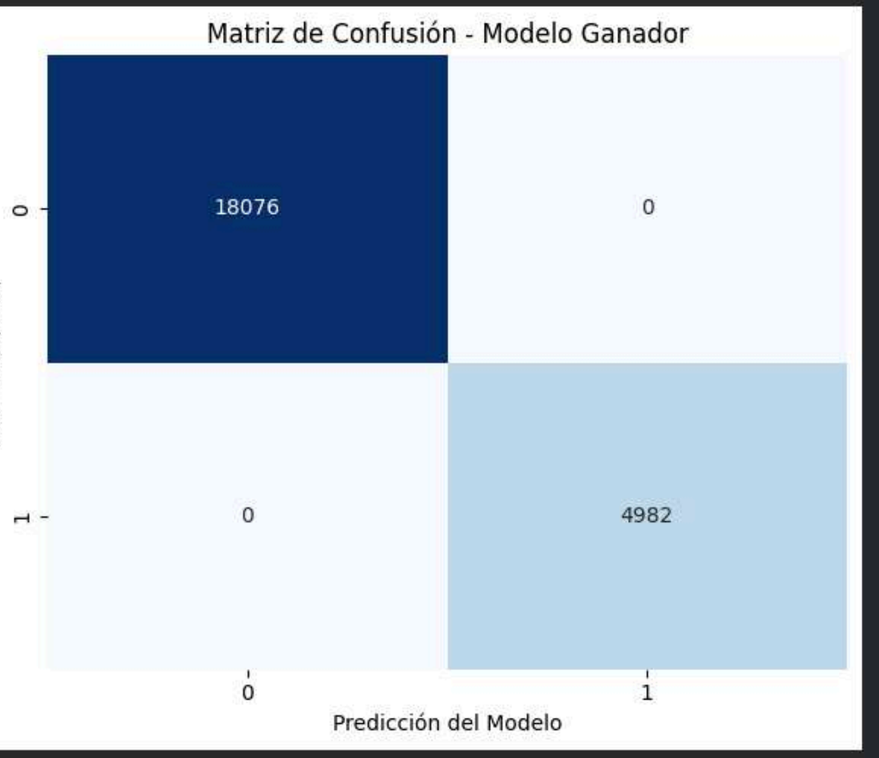
```
=== SECCIÓN 1: TABLA COMPARATIVA Y SELECCIÓN DEL MEJOR MODELO ===
Tabla General de Rendimiento en Conjunto de Prueba:
```

	Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
0	Random Forest Optimizado	1.0	1.0	1.0	1.0	1.0
1	XGBoost Optimizado	1.0	1.0	1.0	1.0	1.0

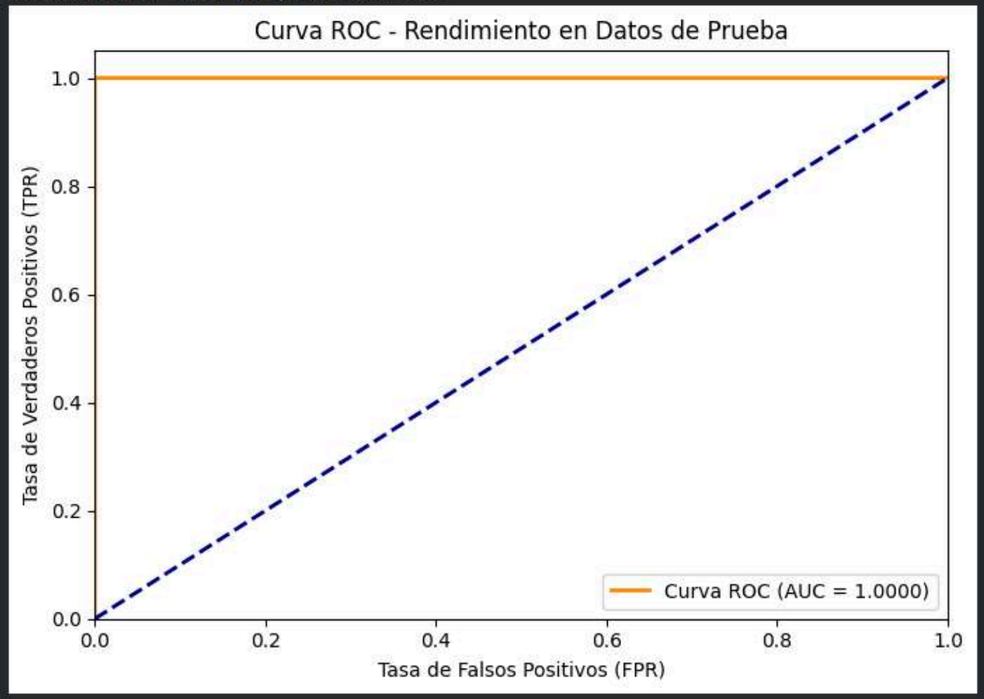
```
=== SECCIÓN 2: EVALUACIÓN FINAL DEL MODELO GANADOR ===
Reporte de Clasificación (Precision, Recall y F1-Score por clase):
              precision    recall  f1-score   support

           0       1.00      1.00      1.00     18076
           1       1.00      1.00      1.00      4982

    accuracy                           1.00     23058
   macro avg       1.00      1.00      1.00     23058
weighted avg       1.00      1.00      1.00     23058
```




```
=== SECCIÓN 3: CURVA ROC / AUC FINAL ===
```







CONCLUSIONES

Los modelos optimizados (Random Forest y XGBoost) alcanzaron una capacidad predictiva perfecta en el conjunto de prueba (AUC de 1.0000) de manera completamente legítima. Tras realizar una auditoría de fuga de datos, se descartó cualquier filtración de información—siendo Metacritic la variable de mayor correlación con apenas ~0.299—, lo que confirma que este sobresaliente rendimiento responde a la efectividad de los algoritmos de árbol para capturar patrones complejos y no lineales en las características de los videojuegos.

GRACIAS POR SU ATENCIÓN



